

Analiza Hcy i ryzyka raka płuca względem genotypu MTHFR 665 C>T

Zadanie 7 · biostatystyka · analiza wykonana w SAS

Temat analizy

Poziom homocysteiny oraz status Case/Control w zależności od genotypu MTHFR665.

Cel prezentacji: pokazać tok rozwiązania, dobór metody statystycznej, wyniki z SAS oraz końcową interpretację.

Zmienna ciągła

Hcy

poziom homocysteiny [$\mu\text{mol/l}$]

Zmienna grupująca

CC / CT / TT

genotyp MTHFR 665 C>T

Status kliniczny

Case / Control

zmienna wynikowa dla modelu logistycznego

Treść zadania i cel analizy

Dwa pytania badawcze: różnice Hcy oraz związek genotypu ze statusem Case/Control

Pytania z zadania

- Czy poziom homocysteiny różni się między genotypami MTHFR665?
- Czy genotyp MTHFR665 wpływa na ryzyko raka płuca rozumiane jako status Case/Control?
- Które wyniki są statystycznie istotne i jak można je zinterpretować biologicznie?

Plan rozwiązania

1. Sprawdzenie liczebności i braków danych.
2. Opis rozkładu Hcy w grupach genotypowych.
3. Ocena normalności rozkładu Hcy.
4. Dobór testu globalnego i post-hoc.
5. Model logistyczny: OR dla CT i TT względem CC.
6. Interpretacja oraz wnioski końcowe.

W prezentacji rozróżniamy istotność statystyczną od znaczenia merytorycznego.

Dane i zmienne użyte w analizie

Liczebności genotypów oraz statusu Case/Control

Tabele z PROC FREQ: MTHFR665 oraz CaseControl

PROC FREQ: MTHFR665				
MTHFR665				
MTHFR665	Frequency	Percent	Cumulative Frequency	Cumulative Percent
CC	446	42.23	446	42.23
CT	508	48.11	954	90.34
TT	102	9.66	1056	100.00

PROC FREQ: CaseControl				
CaseControl				
CaseControl	Frequency	Percent	Cumulative Frequency	Cumulative Percent
Case	264	25.00	264	25.00
Control	792	75.00	1056	100.00

Najważniejsze informacje o próbie

- Łączna liczba obserwacji: 1056.
- Genotypy: CC 42,23%; CT 48,11%; TT 9,66%.
- Status: Case 25,00%; Control 75,00%.
- Dalsze analizy dla Hcy wykorzystują obserwacje niebrakujące w danej grupie.

Uwaga metodologiczna

Nierówne liczebności grup są dopuszczalne, ale wpływają na precyzję estymacji — zwłaszcza w grupie TT.

Zastosowana metoda statystyczna

Dobór testów wynika z typu zmiennych i założeń rozkładu

Część A: Hcy jako zmienna ciągła

- 1 Opis Hcy**
średnia, mediana, SD, min–max
- 2 Normalność**
Shapiro-Wilk osobno dla CC/CT/TT
- 3 Test globalny**
Kruskal-Wallis przy braku normalności
- 4 Post-hoc**
DSCF dla porównań parami

Część B: status Case/Control jako zmienna binarna

- 1 Kodowanie outcome**
1 = Case, 0 = Control
- 2 Regresja logistyczna**
MTHFR665 jako predyktor kategoriyczny
- 3 OR i 95% CI**
CC jako grupa referencyjna
- 4 Tabela χ^2**
niezależność MTHFR665 i CaseControl

Założenie decyzyjne: $p < 0,05$ traktujemy jako wynik istotny statystycznie. Przy interpretacji OR sprawdzamy także, czy 95% CI obejmuje 1.

Kod SAS: analiza poziomu Hcy

Najważniejsze fragmenty kodu dla części A

```
PROC MEANS DATA=dane N NMISS MEAN MEDIAN STD MIN MAX MAXDEC=2;  
  CLASS MTHFR665;  
  VAR Hcy;  
  TITLE "Statystyki opisowe homocysteiny wedlug genotypu MTHFR 665  
C>T";  
RUN;  
  
PROC SGPLOT DATA=dane;  
  VBOX Hcy / CATEGORY=MTHFR665;  
  XAXIS LABEL="Genotyp MTHFR 665 C>T";  
  YAXIS LABEL="Poziom homocysteiny (umol/l)";  
RUN;
```

```
PROC SORT DATA=dane; BY MTHFR665; RUN;  
  
PROC UNIVARIATE DATA=dane NORMAL;  
  BY MTHFR665;  
  VAR Hcy;  
  HISTOGRAM Hcy / NORMAL;  
RUN;  
  
PROC NPAR1WAY DATA=dane WILCOXON DSCF;  
  CLASS MTHFR665;  
  VAR Hcy;  
  TITLE "Kruskal-Wallis + post-hoc DSCF";  
RUN;
```

Kod prowadzi od opisu danych, przez ocenę normalności, do testu nieparametrycznego i analizy post-hoc.

Kod SAS: ryzyko raka płuca

Najważniejsze fragmenty kodu dla części B

```
DATA dane2;
  SET dane;
  IF CaseControl = 'Case' THEN outcome = 1;
  ELSE IF CaseControl = 'Control' THEN outcome = 0;
RUN;

PROC LOGISTIC DATA=dane2;
  CLASS MTHFR665 (REF='CC') / PARAM=REF;
  MODEL outcome(EVENT='1') = MTHFR665 / CLODDS=WALD;
  TITLE "Regresja logistyczna: wpływ genotypu MTHFR 665 C>T";
RUN;
```

```
PROC FREQ DATA=dane;
  TABLES MTHFR665 * CaseControl / CHISQ RELRISK;
  TITLE "Tabela kontyngencji: genotyp MTHFR 665 C>T vs
rak pluca";
RUN;
```

Co oznacza model?

- outcome=1 oznacza przypadek raka płuca.
- Grupa referencyjna: CC.
- OR porównuje CT i TT względem CC.
- 95% CI pozwala ocenić precyzję i istotność efektu.

Wyniki opisowe: poziom Hcy a genotyp MTHFR665


PROC MEANS + PROC SGPLOT

Tabela z PROC MEANS: statystyki opisowe Hcy według genotypu

Analysis Variable : Hcy Hcy								
MTHFR665	N Obs	N	N Miss	Mean	Median	Std Dev	Minimum	Maximum
CC	446	440	6	15.97	14.60	6.43	4.07	43.50
CT	508	506	2	15.81	14.90	5.43	1.96	38.70
TT	102	102	0	17.03	16.00	7.34	7.70	48.10

Co widać w danych opisowych?

- Mediana Hcy: CC 14,60; CT 14,90; TT 16,00 $\mu\text{mol/l}$.
- Średnia: CC 15,97; CT 15,81; TT 17,03 $\mu\text{mol/l}$.
- Grupa TT ma opisowo najwyższy poziom Hcy.
- Różnica opisowa nie oznacza automatycznie istotności statystycznej.



Kolejny krok: sprawdzenie normalności rozkładów Hcy w grupach genotypowych.

Wykres z PROC SGPLOT: boxplot Hcy według genotypu

Ocena normalności rozkładu Hcy

PROC UNIVARIATE: Shapiro-Wilk oraz histogramy z krzywą normalną

Tabele z PROC UNIVARIATE: Tests for Normality

MTHFR665 = CC

Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.901204	Pr < W	<0.0001
Kolmogorov-Smirnov	D	0.110768	Pr > D	<0.0100
Cramer-von Mises	W-Sq	1.616123	Pr > W-Sq	<0.0050
Anderson-Darling	A-Sq	9.668258	Pr > A-Sq	<0.0050

MTHFR665 = CT

Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.940393	Pr < W	<0.0001
Kolmogorov-Smirnov	D	0.085578	Pr > D	<0.0100
Cramer-von Mises	W-Sq	1.149662	Pr > W-Sq	<0.0050
Anderson-Darling	A-Sq	7.069988	Pr > A-Sq	<0.0050


MTHFR665 = TT

Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.783264	Pr < W	<0.0001
Kolmogorov-Smirnov	D	0.173344	Pr > D	<0.0100
Cramer-von Mises	W-Sq	0.835758	Pr > W-Sq	<0.0050
Anderson-Darling	A-Sq	5.381082	Pr > A-Sq	<0.0050

Wniosek z testu Shapiro-Wilka

- We wszystkich trzech grupach $p < 0,0001$.
- Odrzucamy hipotezę o rozkładzie normalnym Hcy.
- Dalsza analiza różnic między genotypami powinna używać testu nieparametrycznego.

Histogramy z PROC UNIVARIATE



Histogramy pokazują prawostronną asymetrię i obserwacje skrajne, szczególnie widoczne w grupie TT.

Test Kruskala-Wallisa: Hcy według genotypu

PROC NPAR1WAY: wynik globalny dla trzech niezależnych grup


Hipotezy testu

- H_0 : rozkład Hcy jest taki sam w grupach CC, CT i TT.
- H_1 : co najmniej jedna grupa różni się od pozostałych.
- Test używa rang, dlatego jest odporniejszy na brak normalności niż klasyczna ANOVA.

Wynik z SAS

Kruskal-Wallis Test		
Chi-Square	DF	Pr > ChiSq
1.7877	2	0.4091

$p = 0,4091 > 0,05 \rightarrow$ brak podstaw do odrzucenia H_0 .



Wykres z PROC NPAR1WAY: rozkład rang Wilcoxona dla Hcy

Analiza post-hoc DSCF

Porównania parami po teście Kruskala-Wallis

Tabela z PROC NPAR1WAY: Pairwise Two-Sided Multiple Comparison Analysis

Pairwise Two-Sided Multiple Comparison Analysis			
Dwass, Steel, Critchlow-Fligner Method			
Variable: Hcy			
MTHFR665	Wilcoxon Z	DSCF Value	Pr > DSCF
CC vs. CT	-0.4819	0.6815	0.8799
CC vs. TT	-1.3249	1.8737	0.3813
CT vs. TT	-1.0739	1.5188	0.5303

Interpretacja porównań parami

- CC vs CT: $p = 0,8799$.
- CC vs TT: $p = 0,3813$.
- CT vs TT: $p = 0,5303$.
- Wszystkie wartości p są większe niż 0,05.
- Wynik post-hoc potwierdza brak istotnych różnic Hcy między parami genotypów.

Wniosek dla części A

W analizowanym zbiorze danych nie stwierdzono istotnego statystycznie wpływu genotypu MTHFR665 na poziom Hcy.

Regresja logistyczna: genotyp a status Case/Control


PROC LOGISTIC: model z CC jako grupą referencyjną

Tabele z PROC LOGISTIC: test globalny, Type 3 i OR

Testing Global Null Hypothesis: BETA=0			
Test	Chi-Square	DF	Pr > ChiSq
Likelihood Ratio	7.2064	2	0.0272
Score	7.2444	2	0.0267
Wald	7.2049	2	0.0273

Type 3 Analysis of Effects			
Effect	DF	Wald Chi-Square	Pr > ChiSq
MTHFR665	2	7.2049	0.0273

Odds Ratio Estimates and Wald Confidence Intervals				
Effect	Unit	Estimate	95% Confidence Limits	
MTHFR665 CT vs CC	1.0000	0.672	0.501	0.901
MTHFR665 TT vs CC	1.0000	0.748	0.453	1.234



Wykres z PROC LOGISTIC: Odds Ratios with 95% Wald Confidence Limits

Interpretacja statystyczna

Model wskazuje związek genotypu z wynikiem Case/Control, ale efekt wymaga ostrożnej interpretacji jako asocjacja.

- CT vs CC: OR = 0,672; 95% CI: 0,501–0,901.
- TT vs CC: OR = 0,748; 95% CI: 0,453–1,234.
- Dla CT przedział ufności nie obejmuje 1; dla TT obejmuje 1.

Tabela kontyngencji i test χ^2

PROC FREQ: MTHFR665 × CaseControl

Tabela z PROC FREQ: Table of MTHFR665 by CaseControl

Table of MTHFR665 by CaseControl			
MTHFR665(MTHFR665)	CaseControl(CaseControl)		
	Case	Control	Total
CC	130	316	446
	12.31	29.92	42.23
	29.15	70.85	
	49.24	39.90	
CT	110	398	508
	10.42	37.69	48.11
	21.65	78.35	
	41.67	50.25	
TT	24	78	102
	2.27	7.39	9.66
	23.53	76.47	
	9.09	9.85	
Total	264	792	1056
	25.00	75.00	100.00

Tabela z PROC FREQ: Chi-Square Tests

Statistic	DF	Value	Prob
Chi-Square	2	7.2444	0.0267
Likelihood Ratio Chi-Square	2	7.2064	0.0272
Mantel-Haenszel Chi-Square	1	4.8890	0.0270
Phi Coefficient		0.0828	
Contingency Coefficient		0.0825	
Cramer's V		0.0828	

Interpretacja tabeli

- Test χ^2 : $p = 0,0267$, więc rozkład genotypów różni się między Case i Control.
- Odsetek Case w obrębie genotypu: CC 29,15%; CT 21,65%; TT 23,53%.
- Cramer's V = 0,0828 sugeruje słabą siłę zależności.

Interpretacja statystyczna i merytoryczna

Oddzielamy wynik matematyczny od wniosku biologicznego

Interpretacja statystyczna

- Hcy: brak istotnych różnic między genotypami MTHFR665.
- Ryzyko Case/Control: genotyp jest istotny w modelu i w tabeli χ^2 .
- Dla CT vs CC OR < 1 i 95% CI nie obejmuje 1.
- Dla TT vs CC wynik jest niejednoznaczny, bo 95% CI obejmuje 1.
- Siła predykcyjna modelu jest słaba: c = 0,549.

Interpretacja merytoryczna

- Polimorfizm MTHFR C>T jest powiązany z metabolizmem folianów i homocysteiny.
- W tym zbiorze nie widać jednak istotnej różnicy Hcy między genotypami.
- Związek z Case/Control należy traktować jako asocjację, a nie dowód przyczynowości.
- Model nie kontroluje potencjalnych zmiennych zakłócających: wieku, płci, palenia, folianów czy witaminy B12.

Źródła naukowe użyte do krótkiego kontekstu biologicznego: [Frosst et al., Nature Genetics 1995](#)

[Mao et al., Journal of Human Genetics 2008](#)

Wnioski końcowe

Odpowiedź na pytania postawione w zadaniu

Pytanie 1: Hcy a genotyp

Nie ma podstaw do stwierdzenia, że poziom homocysteiny różni się istotnie między genotypami CC, CT i TT.

Wynik kluczowy: Kruskal-Wallis $p = 0,4091$.

Pytanie 2: genotyp a ryzyko raka płuca

Genotyp MTHFR665 jest związany ze statusem Case/Control w analizowanym zbiorze.

Wyniki kluczowe: Type 3 $p = 0,0273$; χ^2 $p = 0,0267$.

Wniosek praktyczny

Wyniki sugerują statystyczną asocjację genotypu ze statusem choroby, ale nie wystarczają do wniosku przyczynowego. Silniejsza analiza wymagałaby modelu wieloczynnikowego z kontrolą wieku, płci, palenia i parametrów metabolizmu folianów.

Hcy — brak istotnej różnicy; Case/Control — istotna, lecz słaba zależność z genotypem.

Publikacje naukowe wykorzystane w interpretacji

1. Kontekst biologiczny MTHFR i homocysteiny

Frosst P. et al. A candidate genetic risk factor for vascular disease. Nature Genetics, 1995.

[PubMed](#)

2. Kontekst asocjacji MTHFR z rakiem płuca

Mao R. et al. Methylenetetrahydrofolate reductase gene polymorphisms and lung cancer: a meta-analysis. Journal of Human Genetics, 2008.

[Nature](#)